

Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное учреждение  
высшего образования «Национальный исследовательский университет  
ИТМО»

## **Математическая статистика**

2025–2026 учебный год

### **Расчётно-графическая работа №3**

#### **Регрессионные модели и их интерпретация**

**Авторы:** Смирнов И. С., Лукина М. В.

## 1. Общие сведения

- **Тема РГР №3:** оценивание функции регрессии, построение и сравнение нескольких моделей зависимости результативного признака от одного фактора.
- **Формат:** работа выполняется **в аудитории** на практических занятиях; допускается командная работа **2–3 человека**.
- **Данные:** во всех вариантах используются **реальные наборы данных** или заранее подготовленные **срезы реальных наборов данных**. Для каждого варианта указывается источник данных и правило получения среза.
- **Инструменты:** Python/Colab, Excel, R и др. (на выбор команды). В отчёте должны присутствовать пояснения, формулы и интерпретации результатов.
- **Оценивание:** максимум **15 баллов** (шкала приведена в разделе 6).

## 2. Вариант и данные

Команде выдаётся вариант вида **A–1, B–7, ..., F–15**, CSV-файл с данными и карточка варианта.

Каждый CSV-файл содержит два столбца:

$x$  — фактор (объясняющая переменная),  $y$  — результат (зависимая переменная).

Для каждого варианта в карточке указываются:

- предметная область и краткий прикладной контекст;
- исходный набор данных и его источник;
- правило получения среза (если использовано подмножество исходных данных);
- смысл переменных  $x$  и  $y$ ;
- три модели, которые необходимо сравнить:
  - линейная,
  - квадратичная,
  - одна дополнительная модель, назначенная в варианте;
- прогнозное значение  $x^*$ , для которого требуется получить прогноз по выбранной модели.

## 2.1. Группы и направления подготовки

| Группа | Направления подготовки                                                                                                                                                                                      |
|--------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| A      | Технологии защиты информации; Системное и прикладное программное обеспечение; Компьютерные системы и технологии; Мобильные и сетевые технологии; DevOps в разработке и управлении информационными системами |
| B      | Робототехника и искусственный интеллект; Языковые модели и искусственный интеллект; MLOps: управление системами ИИ                                                                                          |
| C      | Технологии разработки компьютерных игр; Геймдизайн и продюсирование компьютерных игр; Компьютерные технологии в дизайне                                                                                     |
| D      | Бизнес-информатика и управление на основе данных; Инновационные технологии в умном городе; Технологии и инновации                                                                                           |
| E      | Физика наноструктур; Фотоника и оптоинформатика; Физика фотонных технологий                                                                                                                                 |
| F      | Биоинженерия                                                                                                                                                                                                |

## 3. Что сдаём

Сдаётся короткий отчёт (допускается ноутбук), содержащий:

- идентификатор варианта, краткое описание источника данных и правила среза;
- таблицу исходных данных или её фрагмент;
- диаграмму рассеяния и предварительную гипотезу о характере связи;
- построение трёх моделей и запись итоговых уравнений;
- сравнение моделей по качеству приближения;
- расчёт статистических характеристик для линейной модели;
- прогноз для заданного значения  $x^*$ ;
- итоговый содержательный вывод по результатам исследования.

## 4. Задание (обязательная часть)

### 4.1. Первичный анализ данных

Для своего варианта необходимо:

1. загрузить CSV-файл с исходными данными;

2. указать, из какого реального набора данных взят вариант;
3. если используется срез, кратко описать правило его получения;
4. построить диаграмму рассеяния  $(x_i, y_i)$ ;
5. по графику сформулировать гипотезу о форме и направлении связи между  $x$  и  $y$ .

## 4.2. Построение трёх регрессионных моделей

Для данных своего варианта постройте три модели:

1. **линейную модель**

$$y = a + bx;$$

2. **квадратичную модель**

$$y = a + bx + cx^2;$$

3. **дополнительную модель**, указанную в карточке варианта:

$$y = ae^{bx}, \quad y = ax^b, \quad y = a + b \ln x, \quad y = a + \frac{b}{x}$$

(используется только одна из этих моделей — та, которая назначена в варианте).

**Замечание.** При оценивании параметров некоторых моделей удобно предварительно приводить их к линейному виду стандартными заменами переменных. Необходимые формулы линеаризации приведены в приложении.

Для каждой модели необходимо:

1. найти оценки параметров;
2. записать итоговое уравнение регрессии;
3. построить график модели на фоне исходных данных;
4. получить прогнозные значения  $\hat{y}_i$ .

## 4.3. Сравнение моделей

Для трёх построенных моделей:

1. вычислите коэффициент детерминации  $R^2$ ;
2. вычислите среднюю ошибку аппроксимации;
3. проанализируйте графики остатков или характер отклонений модели от данных;

- сделайте вывод, какая модель лучше описывает наблюдаемую зависимость.

**Замечание.** При сравнении моделей необходимо учитывать не только значение  $R^2$ , но и содержательную осмысленность модели, а также характер остатков.

#### 4.4. Подробный статистический анализ линейной модели

Для линейной модели выполните полный расчёт:

- найдите оценки коэффициентов  $\hat{a}$  и  $\hat{b}$ ;
- вычислите прогнозные значения  $\hat{y}_i$  и остатки  $e_i = y_i - \hat{y}_i$ ;
- вычислите остаточную сумму квадратов

$$RSS = \sum_{i=1}^n e_i^2;$$

- вычислите несмещённую оценку дисперсии ошибки

$$s^2 = \frac{RSS}{n-2}, \quad s = \sqrt{s^2};$$

- постройте 95% доверительные интервалы для коэффициентов линейной регрессии;
- проверьте гипотезу

$$H_0: b = 0, \quad H_1: b \neq 0$$

о статистической значимости коэффициента при  $x$  на уровне значимости  $\alpha = 0.05$ ;

- сделайте вывод о статистической значимости коэффициента при  $x$ .

#### 4.5. Прогноз и интерпретация

Для заданного в карточке варианта значения  $x^*$ :

- получите прогноз  $\hat{y}(x^*)$  по каждой из трёх моделей;
- укажите, какую модель вы выбираете как основную для прогноза;
- интерпретируйте полученный результат на языке предметной области.

#### 4.6. Итоговый вывод

В конце отчёта сформулируйте общий итог работы (7–12 строк):

- какой реальный набор данных исследовался;

- какая зависимость изучалась;
- какие модели были построены;
- какая модель оказалась предпочтительной и почему;
- как интерпретировать найденную зависимость содержательно.

## 5. Методические замечания

- Основной статистический блок (остатки, оценка дисперсии ошибок, доверительные интервалы) обязателен для **линейной** модели. Для остальных моделей основной акцент делается на построении, качестве аппроксимации и интерпретации.
- Если выбранная дополнительная модель требует преобразования переменных, это преобразование необходимо явно указать в решении.
- Если в варианте используется срез исходного набора данных, в отчёте следует кратко пояснить, почему такой срез рассматривается как отдельная прикладная задача.
- При использовании библиотек `numpy`, `scipy`, `statsmodels`, `sklearn`, R и др. следует указать, какие функции были использованы при оценивании параметров моделей.

## 6. Оценивание (15 баллов)

Рекомендуемая шкала (может уточняться преподавателем потока):

| Элемент работы                                                 | Баллы     |
|----------------------------------------------------------------|-----------|
| Корректное описание источника данных, среза и первичный анализ | 2         |
| Построение линейной модели и её интерпретация                  | 3         |
| Построение квадратичной модели                                 | 2         |
| Построение дополнительной модели, назначенной в варианте       | 2         |
| Сравнение моделей по качеству и выбор лучшей модели            | 3         |
| Подробный статистический анализ линейной модели                | 2         |
| Прогноз и содержательный итоговый вывод                        | 1         |
| <b>Итого</b>                                                   | <b>15</b> |

## Приложение А. Теоретическая справка

### А.1. Простая линейная регрессия

Рассматривается модель

$$Y_i = \theta_0 + \theta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n,$$

где  $Y_i$  — зависимая переменная,  $X_i$  — объясняющая переменная,  $\theta_0, \theta_1$  — неизвестные параметры,  $\varepsilon_i$  — случайные ошибки.

Функцией регрессии случайной величины  $Y$  на  $X$  называется функция

$$m(x) = E(Y \mid X = x),$$

если соответствующее условное математическое ожидание существует.

### А.2. Оценки МНК для линейной модели

Пусть

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$
$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Тогда оценки коэффициентов линейной регрессии имеют вид

$$\hat{\theta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}.$$

Итоговое уравнение линейной регрессии:

$$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 x.$$

### А.3. Остатки и оценка дисперсии ошибок

Остаток для  $i$ -го наблюдения:

$$e_i = y_i - \hat{y}_i.$$

Остаточная сумма квадратов:

$$RSS = \sum_{i=1}^n e_i^2.$$

Несмещённая оценка дисперсии ошибки:

$$s^2 = \frac{RSS}{n-2}, \quad s = \sqrt{s^2}.$$

#### А.4. Доверительные интервалы для коэффициентов линейной модели

Стандартные ошибки коэффициентов:

$$SE(\hat{\theta}_1) = \frac{s}{\sqrt{S_{xx}}},$$

$$SE(\hat{\theta}_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}.$$

Пусть  $t = t_{1-\alpha/2; n-2}$  — квантиль распределения Стьюдента. Тогда 95% доверительные интервалы имеют вид

$$\hat{\theta}_1 \pm t SE(\hat{\theta}_1), \quad \hat{\theta}_0 \pm t SE(\hat{\theta}_0).$$

Если доверительный интервал для коэффициента  $\theta_1$  не содержит ноль, то линейная зависимость между  $x$  и  $y$  считается статистически значимой на соответствующем уровне значимости.

#### А.5. Проверка гипотезы о значимости коэффициента при $x$

Для линейной модели при проверке статистической значимости коэффициента наклона рассматриваются гипотезы

$$H_0: \theta_1 = 0, \quad H_1: \theta_1 \neq 0.$$

Используется статистика Стьюдента

$$t_{\text{набл}} = \frac{\hat{\theta}_1}{SE(\hat{\theta}_1)},$$

которая при справедливости гипотезы  $H_0$  имеет распределение Стьюдента с  $n - 2$  степенями свободы.

На уровне значимости  $\alpha$  гипотеза  $H_0$  отвергается, если

$$|t_{\text{набл}}| > t_{1-\alpha/2; n-2}.$$

Эквивалентно, гипотеза  $H_0$  отвергается тогда и только тогда, когда ноль не попадает в



доверительный интервал для коэффициента  $\theta_1$ .

## А.6. Коэффициент детерминации

Общая сумма квадратов:

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{RSS}{TSS}.$$

Коэффициент  $R^2$  показывает, какая доля изменчивости зависимой переменной объясняется построенной моделью.

## А.7. Модели, допускаемые в РГР №3

В работе используются следующие типы моделей:

|                      |                        |
|----------------------|------------------------|
| линейная:            | $y = a + bx,$          |
| квадратичная:        | $y = a + bx + cx^2,$   |
| показательная:       | $y = ae^{bx},$         |
| степенная:           | $y = ax^b,$            |
| полулогарифмическая: | $y = a + b \ln x,$     |
| гиперболическая:     | $y = a + \frac{b}{x}.$ |

При оценивании параметров следующие модели могут быть приведены к линейному виду:

- показательная модель:  $\ln y = \ln a + bx$ ;
- степенная модель:  $\ln y = \ln a + b \ln x$ ;
- полулогарифмическая модель уже имеет вид  $y = a + b \ln x$ ;
- гиперболическая модель:  $y = a + bz$ , где  $z = 1/x$ .

**Важно.** При использовании преобразований необходимо следить за областью допустимых значений переменных. Например, в показательной и степенной моделях должны быть корректно определены логарифмы.

## А.8. Средняя ошибка аппроксимации

В качестве одной из мер качества модели можно использовать среднюю относительную ошибку аппроксимации

$$A = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|,$$

если значения  $y_i$  ненулевые.

## А.9. Вопросы для итогового вывода

В заключении рекомендуется ответить на вопросы:

1. Какой вид имеет найденная зависимость между  $x$  и  $y$ ?
2. Является ли связь положительной или отрицательной?
3. Какая из трёх моделей лучше описывает данные?
4. Насколько линейная модель статистически значима?
5. Как интерпретируется прогноз для заданного значения  $x^*$ ?